Introducción a las Tecnologías del Habla

Trabajo Práctico 1 Etapa III: Tests de Hipótesis

> Departamento de Computación, Facultad de Ciencias Exactas y Naturales, Universidad de Buenos Aires

> > Segundo Cuatrimestre de 2012

Alumno Leandro Lovisolo LU 645/11

Introducción

El objetivo de este TP es juntar evidencia a favor de un determinado conjunto de hipótesis, utilizando el corpus de grabaciones recolectado y transcrito por todos los alumnos de esta materia en las fases I y II de este mismo TP.

El conjunto de hipótesis elegido es el siguiente:

- 1. Los hablantes de mayor edad suelen usar palabras de mayor longitud.
- 2. Los hombres tienen un tono de voz más grave que las mujeres.
- 3. El habla espontánea tiene un tono de voz más grave que el habla leída.

Materiales y métodos

Para la realización de los tests de hipótesis se obtuvieron tres datos por cada sujeto: la longitud promedio de las palabras empleadas, la frecuencia fundamental promedio del habla espontánea y la frecuencia fundamental promedio del habla leída.

La longitud promedio de las palabras empleadas se obtuvo a partir de los archivos IPU, de los que se tomaron las palabras anotadas y se calculó el promedio simple de la longitud de las mismas, descartando los silencios marcados con el símbolo #.

Las frecuencias fundamentales promedio se obtuvieron en cada caso de las tareas de lectura y de habla espontánea a partir del output en formato CSV del script praat.py provisto por la cátedra. De estos CSV se calculó el promedio simple de los valores bajo la columna fo_mean, descartando las celdas de valor -1. Se utilizaron los valores por defecto de parámetros MIN_PITCH, MAX_PITCH, WINDOW_SIZE y STEP (100Hz, 850Hz, 0.2s y 0.1s, respectivamente.)

Para el procesamiento de los archivos IPU y CSV se creó un script en lenguaje Python. Para los cálculos de los tests de hipótesis y generación de plots se utilizó el software R. Los tests de correlación se realizaron con el comando cor.test, y los t-tests de Student con el comando t.test.

Tanto el script Python como los scripts R se encuentran disponibles en la siguiente URL, en la que además se incluye parte del corpus, los outputs del script Python y los plots generados con los scripts R:

https://github.com/LeandroLovisolo/ITH-TP1

Resultados

Hipótesis 1: Los hablantes de mayor edad suelen usar palabras de mayor longitud

Se desea estudiar la correlación entre la edad de las personas y la longitud promedio de las palabras que estas emplean.

H₀: No existe correlación entre la edad y la longitud de las palabras empleadas por un sujeto.

H_A: Sí existe correlación entre la edad y la longitud de las palabras empleadas por un sujeto.

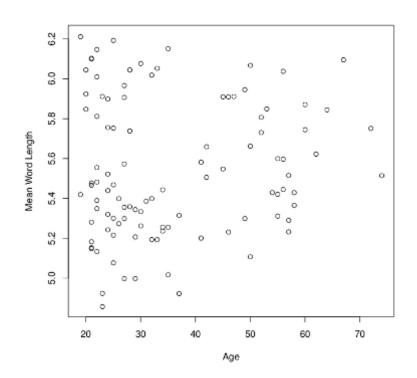
Se utilizaron 103 pares edad/longitud promedio como muestra para la realización de un test de correlación.

Output del test obtenido con el software R:

```
Pearson's product-moment correlation

data: age and mean_word_length
t = 0.9978, df = 101, p-value = 0.3208
alternative hypothesis: true correlation is not equal to 0
95 percent confidence interval:
-0.09657621 0.28683550
sample estimates:
cor
0.09879492
```

Plot de la muestra:



Hipótesis 2: Los hombres tienen un tono de voz más grave que las mujeres

Se desea determinar si existe una diferencia en la frecuencia fundamental promedio entre hombre y la mujer.

 H_0 : La F_0 promedio del hombre y la mujer son iguales. H_A : La F_0 promedio del hombre es más grave que la F_0 de la mujer.

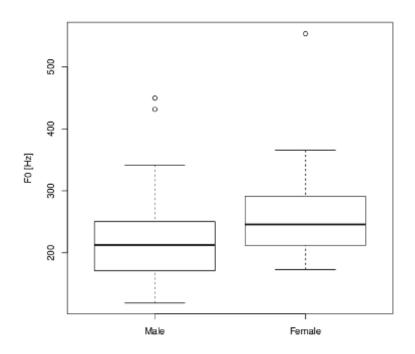
La muestra en este caso fue la frecuencia fundamental promedio de 55 hombres y 56 mujeres, las cuales se sometieron a un t-test.

Output del test obtenido con el software R:

```
Welch Two Sample t-test

data: males and females
t = -2.8349, df = 107.672, p-value = 0.005476
alternative hypothesis: true difference in means is not equal to 0
95 percent confidence interval:
-58.87711 -10.42141
sample estimates:
mean of x mean of y
221.6457 256.2950
```

Plot de la muestra:



Hipótesis 3: El habla espontánea tiene un tono de voz más grave que el habla leída

Se desea determinar si existe una diferencia en la frecuencia fundamental promedio entre el habla espontánea y el habla leída de las personas.

 H_0 : La F_0 promedio del habla espontánea y el habla leída son iguales. H_A : La F_0 promedio del habla espontánea es más grave que la F_0 del habla leída.

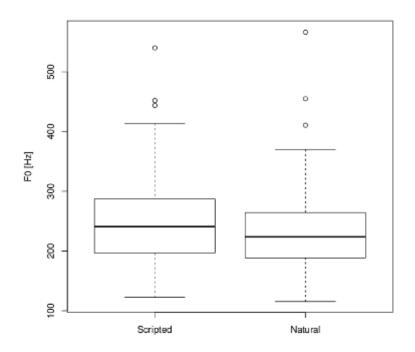
Se realizó un t-test cuya muestra consistió en pares frecuencia fundamental espontánea/ leída obtenidos de 111 sujetos distintos.

Output del test obtenido con el software R:

```
Welch Two Sample t-test
```

```
data: scripted_mean_f0 and natural_mean_f0
t = 1.7262, df = 219.436, p-value = 0.08573
alternative hypothesis: true difference in means is not equal to 0
95 percent confidence interval:
    -2.232506 33.733230
sample estimates:
mean of x mean of y
    247.0016 231.2512
```

Plot de la muestra:



Conclusiones

Hipótesis 1: Los hablantes de mayor edad suelen usar palabras de mayor longitud

No tenemos suficiente evidencia para sostener esta hipótesis.

Se obtuvo un p-valor de 0.3208, lo cual sugiere que no existe una correlación entre los parámetros estudiados, y esto se refleja claramente en el plot de la misma.

Hipótesis 2: Los hombres tienen un tono de voz más grave que las mujeres

Se obtuvo fuerte evidencia de esta hipótesis.

El p-valor obtenido es de 0.005476, un orden de magnitud por debajo de nuestra cota superior (0.05). Esto se manifiesta muy claro en los box plots, donde se observa que la mediana de la F_0 de los sujetos de sexo femenino está muy cerca del cuartil superior de la F_0 de los sujetos de sexo masculino.

Hipótesis 3: El habla espontánea tiene un tono de voz más grave que el habla leída

Se obtuvo evidencia aproximadamente significativa de esta hipótesis.

Si bien existe una diferencia en la F_0 visible en los box plots, el p-valor obtenido es de 0.08573, el cual está por encima de nuestra cota de 0.05. Para los fines de nuestro trabajo no tenemos suficiente evidencia para soportar esta hipótesis.